Rapport de Projet machine learning

Parcours : Data Science

Détection du cancer du sein : une application des algorithmes d'apprentissage automatique sur le jeu de données diagnostiques du Wisconsin

Par
Ines Ben Dhifallah, Najeh Ben Rebah, Mohamed Ali Jabri, Mohamed Khalil Kamessi et Feryel Ifaoui

Année Universitaire : 2025-2026

Table des matières

Introduction Générale **1**

1 Cadre de projet **2**
1.1 Introduction 2
1.2 Contexte général 2
1.3 Critique de l'existant 2
1.3.1 Description de l'existant 2
1.3.2 Limites de l'existant 3
1.4 Problématique 3
1.5 Solution proposée 3
1.6 Méthodologie de travail 3
1.7 Conclusion 4

2 Réalisation **5**
2.1 Introduction 5
2.2 Technologies utilisées 5
2.3 Compréhension du métier 5
2.4 Compréhension des données 6
2.4.1 Description générale du dataset 6
2.4.2 Exploration des données (EDA) 6
2.5 Préparation des données 10
2.5.1 Nettoyage des données 10
2.5.2 Encodage de la variable cible 10
2.5.3 Séparation des features et de la cible 11
2.5.4 Division Train-Test 11
2.5.5 Normalisation des données 11
2.6 Modélisation 11
2.6.1 Choix des modèles 11
2.6.2 Optimisation des hyperparamètres 12
2.6.3 Stratégie d'entraînement 12
2.6.4 Interprétabilité des modèles 12
2.6.5 Sauvegarde des modèles 13
2.7 Évaluation 13
2.7.1 Métriques d'évaluation 13
2.7.2 Résultats comparatifs 13
2.7.3 Analyse des résultats 13
2.7.4 Meilleur modèle 14
2.8 Déploiement 14

2.8.1 Architecture de l'application 14
2.8.2 Backend - API FastAPI 14
2.8.3 Frontend - Interface React 15
2.8.4 Communication Frontend-Backend 15
2.8.5 Présentation de l'interface 16
2.8.6 Perspectives d'amélioration 18
2.9 Conclusion 18

Conclusion Générale **19**

Table des figures

1.1 Représentation graphique de la méthodologie CRISP-DM 4

2.1 Statistiques descriptives des variables - Partie 1 7
2.2 Statistiques descriptives des variables - Partie 2 7
2.3 Matrice de corrélation des variables numériques du dataset WDBC 9
2.4 Page d'accueil de l'application 16
2.5 Interface de saisie manuelle des caractéristiques 16
2.6 Interface d'upload d'image 17
2.7 Affichage des résultats de prédiction 17

Liste des tableaux

2.1 Stack technologique du projet 5
2.2 Comparaison des performances des modèles sur l'ensemble de test 13

Introduction Générale

Le cancer du sein représente aujourd'hui l'un des défis majeurs de santé publique à l'échelle mondiale. Selon l'Organisation Mondiale de la Santé (OMS), il constitue le cancer le plus fréquemment diagnostiqué chez les femmes, avec plus de 2,3 millions de nouveaux cas recensés chaque année. Face à cette réalité préoccupante, le diagnostic précoce s'impose comme un facteur déterminant dans l'amélioration des taux de survie et la réduction de la mortalité associée à cette maladie.

Traditionnellement, le diagnostic du cancer du sein repose sur l'expertise médicale, l'imagerie par mammographie et l'analyse histopathologique de biopsies. Bien que ces méthodes aient fait leurs preuves, elles présentent certaines limites : coût élevé, temps d'analyse parfois long, variabilité inter-observateurs et risque d'erreurs humaines. Dans ce contexte, l'intelligence artificielle et le Machine Learning émergent comme des outils prometteurs pour assister les professionnels de santé dans leurs décisions diagnostiques.

L'abondance croissante des données médicales numériques, combinée aux avancées récentes en apprentissage automatique, ouvre des perspectives nouvelles pour le développement de systèmes d'aide à la décision clinique. Le Wisconsin Diagnostic Breast Cancer Dataset (WDBC), largement utilisé dans la recherche académique, offre un terrain d'expérimentation idéal pour entraîner et évaluer des modèles de classification capables de distinguer les tumeurs malignes des tumeurs bénignes avec une précision élevée.

Cependant, malgré les performances impressionnantes rapportées dans la littérature scientifique, la majorité des travaux restent confinés au domaine académique, sans aboutir à des applications concrètes accessibles aux utilisateurs finaux. Le fossé persiste entre la recherche et la pratique clinique, principalement en raison de l'absence d'interfaces utilisateur intuitives et de stratégies de déploiement opérationnel.

C'est dans ce contexte que s'inscrit notre projet : développer un système intelligent et interactif de diagnostic du cancer du sein, combinant les performances des algorithmes de Machine Learning avec une interface web moderne et accessible. Notre objectif est de franchir le pas du laboratoire vers l'application pratique, en proposant une solution permettant aux professionnels de santé d'obtenir des prédictions fiables et expliquées en temps réel.

Ce rapport s'articule autour de deux chapitres principaux. Le premier chapitre établit le cadre général du projet, en présentant le contexte médical, l'analyse critique de l'existant, la problématique et la solution proposée, ainsi que la méthodologie CRISP-DM adoptée. Le second chapitre décrit la réalisation complète du système, depuis l'exploration des données jusqu'au déploiement de l'application web basée sur React et FastAPI, en passant par les phases de préparation, de modélisation et d'évaluation.

À travers ce travail, nous espérons contribuer à l'effort collectif visant à améliorer le diagnostic précoce du cancer du sein, en démontrant que l'intelligence artificielle peut constituer un allié précieux pour les professionnels de santé, à condition d'être rendue accessible, fiable et explicable.

Chapitre 1

Cadre de projet

1.1 Introduction

Ce chapitre présente le cadre général du projet de développement d'un système intelligent de diagnostic du cancer du sein basé sur le Machine Learning. Nous commencerons par exposer le contexte médical et technologique dans lequel s'inscrit ce projet, puis nous analyserons de manière critique les solutions existantes pour en identifier les limites. Cette analyse nous conduira à formuler la problématique du projet et à proposer une solution adaptée. Enfin, nous présenterons la méthodologie CRISP-DM qui guidera l'ensemble du processus de réalisation.

1.2 Contexte général

Le cancer du sein est l'un des cancers les plus répandus chez les femmes dans le monde. Son diagnostic précoce joue un rôle crucial dans l'amélioration du taux de survie des patientes. Traditionnellement, le diagnostic repose sur l'expertise médicale, l'imagerie médicale et l'analyse de biopsies. Cependant, ces méthodes peuvent être coûteuses, longues et sujettes à des erreurs humaines.

Avec l'augmentation des données médicales disponibles, plusieurs travaux ont exploré l'utilisation du Machine Learning pour assister les médecins dans la détection du cancer du sein, notamment à partir du Wisconsin Diagnostic Breast Cancer Dataset (WDBC).

1.3 Critique de l'existant

Dans cette section nous allons commencer par décrire l'existant et présenter les limites de l'existant.

1.3.1 Description de l'existant

Le dataset Wisconsin Diagnostic Breast Cancer (WDBC) est largement utilisé pour entraîner et évaluer des modèles de Machine Learning pour la détection du cancer du sein. Il contient des caractéristiques des cellules mammaires extraites de biopsies, permettant de classer les tumeurs en malignes ou bénignes. Plusieurs modèles ont été testés sur ce dataset, tels que SVM, MLP, Random Forest, Softmax Regression, et même des

modèles hybrides comme GRU-SVM. Ces modèles atteignent généralement des performances élevées, souvent supérieures à 90

1.3.2 Limites de l'existant

— Les travaux se concentrent surtout sur les performances des modèles, sans proposer de moyen pratique pour tester ou utiliser les modèles.
— Il n'existe pas d'interface interactive permettant aux utilisateurs de comparer les modèles ou d'obtenir des prédictions en temps réel.
— Les aspects de déploiement, suivi et maintenance des modèles (MLOps) sont peu ou pas abordés.
— L'utilisation d'un seul dataset standardisé limite la généralisation des modèles à d'autres populations ou types de données médicales.

1.4 Problématique

Bien que les modèles de Machine Learning pour la détection du cancer du sein soient précis sur le dataset WDBC, ils restent difficiles à utiliser dans la pratique. Il n'existe pas de moyen simple pour tester, comparer et exploiter ces modèles en temps réel, ce qui limite leur adoption par les utilisateurs finaux et leur impact clinique.

1.5 Solution proposée

Développer une application interactive qui :
— Permet de tester différents modèles sur le dataset WDBC en temps réel.
— Affiche de manière claire et visuelle les performances comparatives des modèles.
— Facilite le déploiement et la maintenance des modèles grâce à des pratiques MLOps.
— Prépare le système pour une extension future à d'autres datasets ou données réelles.

1.6 Méthodologie de travail

Le projet suit la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining), qui est un standard pour les projets de data mining et de Machine Learning. Cette méthodologie se compose de six étapes principales :
— Compréhension du métier (Business Understanding) : définir les objectifs du projet et comprendre le problème à résoudre.
— Compréhension des données (Data Understanding) : explorer et analyser les données disponibles pour identifier leur qualité et leur pertinence.
— Préparation des données (Data Preparation) : nettoyer, transformer et sélectionner les données pour l'entraînement des modèles.
— Modélisation (Modeling) : choisir et entraîner des modèles de Machine Learning adaptés au problème.
— Évaluation (Evaluation) : vérifier que les modèles répondent aux objectifs et analyser leurs performances.
— Déploiement (Deployment) : mettre en place une solution opérationnelle permettant d'exploiter les modèles.

Cette méthodologie structurée et itérative permet de garantir la qualité des modèles tout en facilitant leur utilisation pratique.
La figure ci-dessous représente la méthodologie crisp-dm.

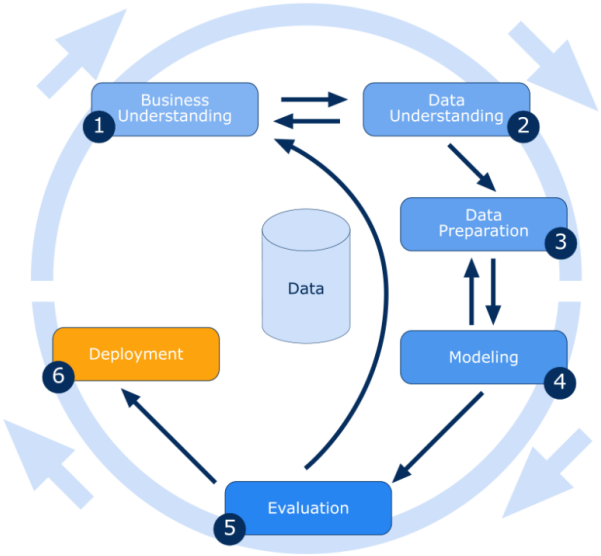

FIGURE 1.1 – Représentation graphique de la méthodologie CRISP-DM

1.7 Conclusion

Ce chapitre a posé les fondations du projet en établissant le contexte médical du cancer du sein et l'importance d'un diagnostic précoce. L'analyse critique de l'existant a révélé que malgré les performances élevées des modèles de Machine Learning sur le dataset WDBC, leur utilisation pratique reste limitée par l'absence d'interfaces interactives et de déploiement opérationnel.

Chapitre 2

Réalisation

2.1 Introduction

Ce chapitre présente la mise en œuvre concrète du système de diagnostic du cancer du sein en suivant la méthodologie CRISP-DM. Nous détaillerons successivement les phases de compréhension des données, de préparation, de modélisation, d'évaluation et de déploiement, permettant ainsi de transformer le dataset WDBC en une application web fonctionnelle d'aide au diagnostic médical.

2.2 Technologies utilisées

Le Tableau 2.1 récapitule l'ensemble des technologies utilisées par catégorie.

Table 2.1 – Stack technologique du projet

Catégorie	**Technologies**
Langages	Python , JavaScript
ML/Data Science	Pandas, NumPy, Scikit-learn, XGBoost, PyTorch
Visualisation	Matplotlib, Seaborn
Explicabilité	LIME
Backend	FastAPI, Uvicorn, Pydantic
Frontend	React
Documentation	LaTeX, Overleaf

2.3 Compréhension du métier

Le diagnostic du cancer du sein repose sur l'analyse de biopsies, ce qui peut être long et subjectif. Les modèles de Machine Learning existants montrent de bonnes performances sur le dataset WDBC, mais ne sont pas facilement utilisables par les médecins. L'objectif de ce projet est donc de développer un système interactif permettant de :

— Détecter automatiquement les tumeurs malignes ou bénignes.
— Comparer les performances de différents modèles.
— Fournir aux médecins un outil d'aide au diagnostic simple, rapide et fiable.

2.4 Compréhension des données

L'objectif de cette phase est d'explorer en profondeur le dataset Wisconsin Diagnostic Breast Cancer (WDBC) afin d'identifier ses caractéristiques principales, de détecter d'éventuelles anomalies et de comprendre les relations entre les variables. Cette analyse exploratoire guidera les décisions lors des phases ultérieures de préparation et de modélisation.

2.4.1 Description générale du dataset

Le dataset Wisconsin Diagnostic Breast Cancer (WDBC) utilisé dans ce projet contient 569 échantillons et 33 colonnes. La colonne diagnosis représente la classe cible, indiquant si la tumeur est maligne (M) ou bénigne (B). La colonne id correspond à l'identifiant unique de chaque échantillon et n'est pas utilisée pour l'entraînement des modèles.

Les autres colonnes représentent des caractéristiques numériques extraites des images de biopsies mammaires. Ces caractéristiques décrivent la forme, la texture et la structure des cellules tumorales, et sont regroupées en trois types de mesures : moyenne (mean), erreur standard (se) et valeur maximale (worst). Voici la description des principales colonnes :

- `radius_mean`, `radius_se`, `radius_worst` : rayon moyen, erreur standard et valeur maximale des cellules.
- `texture_mean`, `texture_se`, `texture_worst` : variation de la texture des cellules.
- `perimeter_mean`, `perimeter_se`, `perimeter_worst` : périmètre moyen, erreur standard et maximum des cellules.
- `area_mean`, `area_se`, `area_worst` : surface moyenne, erreur standard et maximum des cellules.
- `smoothness_mean`, `smoothness_se`, `smoothness_worst` : lissage des contours cellulaires.
- `compactness_mean`, `compactness_se`, `compactness_worst` : compacité des cellules, mesurant la densité et l'irrégularité.
- `concavity_mean`, `concavity_se`, `concavity_worst` : profondeur des concavités des contours.
- `concave_points_mean`, `concave_points_se`, `concave_points_worst` : nombre de points concaves.
- `symmetry_mean`, `symmetry_se`, `symmetry_worst` : symétrie des cellules.
- `fractal_dimension_mean`, `fractal_dimension_se`, `fractal_dimension_worst` : dimension fractale des cellules, reflétant la complexité des contours.

La colonne `Unnamed: 32` est vide et ne sera pas utilisée dans l'analyse.

2.4.2 Exploration des données (EDA)

Statistiques descriptives

Le tableau de statistiques descriptives fournit un aperçu complet des caractéristiques numériques du dataset. Il présente pour chaque variable : le nombre d'observations, la moyenne, l'écart-type, les valeurs minimale et maximale, ainsi que les quartiles (25%, 50% et 75%).

Les Figures 2.1 et 2.2 présentent les statistiques descriptives de l'ensemble des variables du dataset.

concave points_mean	symmetry_mean	...	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst
569.000000	569.000000	...	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
0.048919	0.181162	...	25.677223	107.261213	880.583128	0.132369	0.254265	0.272188
0.038803	0.027414	...	6.146258	33.602542	569.356993	0.022832	0.157336	0.208624
0.000000	0.106000	...	12.020000	50.410000	185.200000	0.071170	0.027290	0.000000
0.020310	0.161900	...	21.080000	84.110000	515.300000	0.116600	0.147200	0.114500
0.033500	0.179200	...	25.410000	97.660000	686.500000	0.131300	0.211900	0.226700
0.074000	0.195700	...	29.720000	125.400000	1084.000000	0.146000	0.339100	0.382900
0.201200	0.304000	...	49.540000	251.200000	4254.000000	0.222600	1.058000	1.252000

FIGURE 2.1 – Statistiques descriptives des variables - Partie 1

concave points_worst	symmetry_worst	fractal_dimension_worst	Unnamed: 32
569.000000	569.000000	569.000000	0.0
0.114606	0.290076	0.083946	NaN
0.065732	0.061867	0.018061	NaN
0.000000	0.156500	0.055040	NaN
0.064930	0.250400	0.071460	NaN
0.099930	0.282200	0.080040	NaN
0.161400	0.317900	0.092080	NaN
0.291000	0.663800	0.207500	NaN

FIGURE 2.2 – Statistiques descriptives des variables - Partie 2

Observations principales :

- **Dataset complet** : L'ensemble des 569 échantillons ne présente aucune valeur manquante pour les variables d'intérêt. Seule la colonne `Unnamed: 32` contient uniquement des valeurs NaN et sera supprimée.
- **Échelles très différentes** : Les variables présentent des échelles extrêmement variées. Par exemple :
  - `area_worst` : varie de 185,2 à 4254,0 (moyenne = 880,6)
  - `perimeter_worst` : varie de 50,41 à 251,2 (moyenne = 107,3)
  - `smoothness_worst` : varie de 0,071 à 0,223 (moyenne = 0,132)
  - `fractal_dimension_worst` : varie de 0,055 à 0,208 (moyenne = 0,084)

Cette grande disparité d'échelles nécessitera obligatoirement une normalisation (StandardScaler ou MinMaxScaler) avant l'entraînement des modèles.

- **Variabilité hétérogène** : Les écarts-types révèlent des variabilités très différentes :
  - Forte variabilité : `area_worst` (std = 569,4), `perimeter_worst` (std = 33,6)
  - Faible variabilité : `fractal_dimension_worst` (std = 0,018), `smoothness_worst` (std = 0,023)
- **Valeurs minimales à zéro** : Plusieurs variables présentent des valeurs minimales égales à zéro :
  - `concave_points_mean` : min = 0,0
  - `concave_points_worst` : min = 0,0
  - `concavity_worst` : min = 0,0

  Cela suggère l'existence de tumeurs sans points concaves détectables, typiquement des tumeurs bénignes à contours réguliers.

Détection des valeurs aberrantes

L'analyse des boxplots révèle la présence de valeurs aberrantes (outliers) dans plusieurs variables du dataset WDBC.

Identification des outliers : Les variables suivantes présentent des valeurs aberrantes significatives :

- `radius_mean`, `perimeter_mean` et `area_mean` : Présence de nombreux outliers supérieurs, correspondant à des cellules de taille exceptionnellement grande.
- `texture_mean` : Quelques outliers supérieurs et inférieurs, indiquant des variations de texture inhabituelles.
- `smoothness_mean` : Plusieurs outliers supérieurs, représentant des cellules avec des contours particulièrement irréguliers.
- `compactness_mean` : Nombreux outliers supérieurs, suggérant des cas de compacité cellulaire très élevée.

Interprétation clinique des valeurs aberrantes : Dans le contexte médical de la détection du cancer du sein, ces valeurs aberrantes ne constituent pas des erreurs de mesure mais revêtent une importance particulière :

- **Signification clinique** : Ces outliers représentent des morphologies tumorales extrêmes et atypiques (cellules anormalement grandes, fortement irrégulières ou présentant une forte asymétrie). Ces caractéristiques sont fortement associées à la malignité des tumeurs.
- **Valeur informationnelle** : Les valeurs aberrantes élevées constituent des signaux discriminants cruciaux permettant d'identifier les cas les plus agressifs de cancer. Elles fournissent des informations essentielles pour distinguer les tumeurs malignes des tumeurs bénignes.
- **Implication pour le prétraitement** : Par conséquent, la suppression de ces outliers est fortement déconseillée. Leur élimination entraînerait une perte d'informations critiques, réduisant la capacité du modèle à détecter les cas de malignité avec une sensibilité élevée.
- **Stratégie de normalisation** : La présence de ces valeurs extrêmes impose l'utilisation d'une technique de normalisation robuste (comme la standardisation via

`StandardScaler`) pour garantir qu'elles n'influencent pas de manière disproportionnée les coefficients du modèle, tout en préservant leur pouvoir discriminant.

Conclusion : Les valeurs aberrantes détectées seront conservées dans le dataset car elles représentent des cas cliniques réels et porteurs d'informations diagnostiques essentielles. Une normalisation appropriée sera appliquée lors de la phase de préparation des données pour gérer leur impact tout en préservant leur contribution au modèle de classification.

Analyse de corrélation

L'analyse de corrélation permet d'identifier les relations entre les variables et de détecter la multicolinéarité.

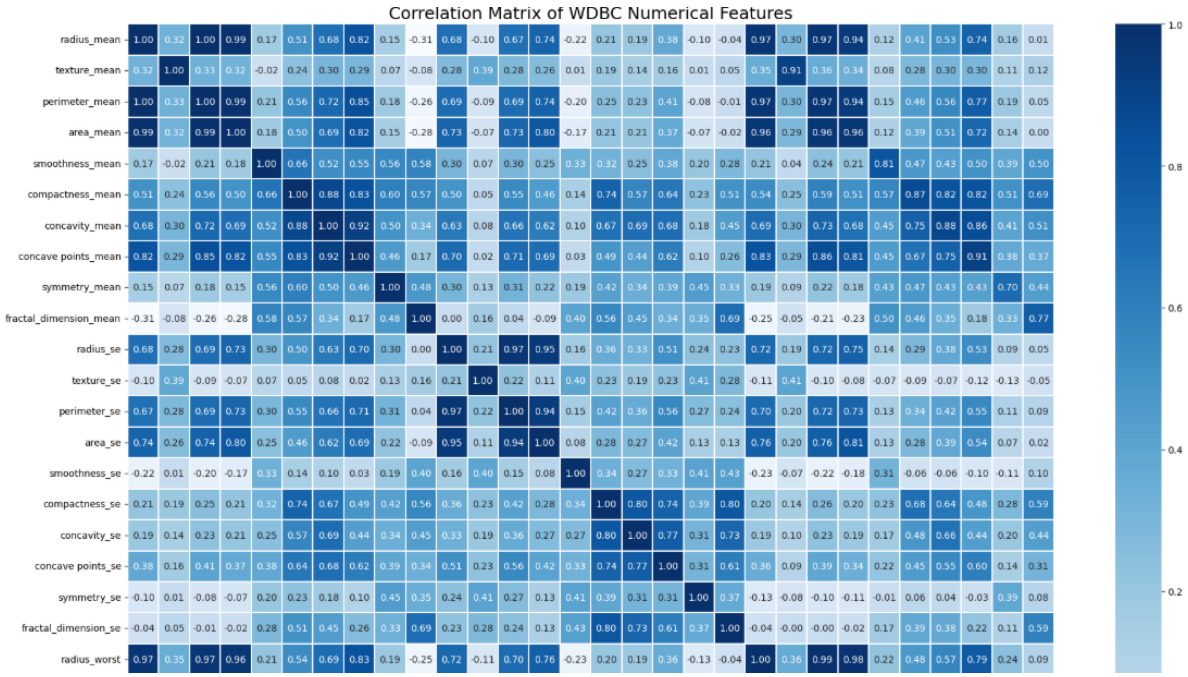

FIGURE 2.3 – Matrice de corrélation des variables numériques du dataset WDBC

Observations principales :

- **Corrélations très fortes entre variables géométriques** :
  - `radius_mean` `perimeter_mean` : r = 1,00
  - `radius_mean` `area_mean` : r = 0,99
  - `perimeter_mean` `area_mean` : r = 0,99

  Ces corrélations quasi-parfaites s'expliquent par les relations mathématiques entre rayon, périmètre et aire.
- **Forte multicolinéarité** : Les trois versions (mean, se, worst) d'une même caractéristique sont fortement corrélées (r supérieur à 0,65), indiquant une redondance d'information.
- **Corrélations élevées pour compacité et concavité** :
  - `compactness_mean` `concavity_mean` : r = 0,88
  - `concavity_mean` `concave_points_mean` : r = 0,92
- **Variables complémentaires** : `texture`, `symmetry` et `fractal_dimension` présentent des corrélations faibles à modérées avec les autres variables, apportant une information orthogonale.

Analyse des valeurs manquantes

L'analyse des valeurs manquantes permet d'évaluer la qualité et la complétude du dataset.

Résultats :

- **Dataset complet** : Les 569 échantillons ne présentent aucune valeur manquante pour l'ensemble des 32 variables d'intérêt (de `id` à `fractal_dimension_worst`).
- **Colonne vide identifiée** : Seule la colonne `Unnamed: 32` contient 569 valeurs manquantes (100% du dataset), confirmant qu'elle est totalement vide et sans information utile.

Conclusion : Le dataset WDBC est de très bonne qualité avec aucune valeur manquante dans les variables pertinentes, ce qui facilite le processus de modélisation et évite les biais liés aux méthodes d'imputation.

2.5 Préparation des données

La phase de préparation des données consiste à transformer le dataset brut en un format adapté à l'entraînement des modèles de Machine Learning. Cette étape est cruciale pour garantir la qualité et les performances des algorithmes de classification.

2.5.1 Nettoyage des données

Suppression des colonnes non pertinentes

Deux colonnes ont été supprimées du dataset car elles n'apportent aucune information utile pour la modélisation :

- **Colonne `Unnamed: 32`** : Cette colonne est totalement vide (100% de valeurs manquantes) et ne contient aucune information exploitable.
- **Colonne `id`** : Il s'agit d'un identifiant unique pour chaque échantillon qui ne possède aucun pouvoir prédictif pour le diagnostic. Son inclusion pourrait causer un sur-apprentissage si le modèle mémorisait les identifiants au lieu d'apprendre les patterns des caractéristiques.

Après cette étape, le dataset contient 569 échantillons et 31 colonnes (30 features + 1 variable cible).

2.5.2 Encodage de la variable cible

La variable cible `diagnosis` est catégorielle avec deux valeurs : `M` (Maligne) et `B` (Bénigne). Pour permettre son utilisation dans les algorithmes de classification, un encodage numérique a été appliqué à l'aide de `LabelEncoder` :

- `B` (Bénigne) $\rightarrow$ 0
- `M` (Maligne) $\rightarrow$ 1

Cette transformation binaire est appropriée pour notre problème de classification binaire.

2.5.3 Séparation des features et de la cible

Le dataset a été divisé en deux parties :
— **X** : Matrice des features (30 variables numériques)
— **y** : Vecteur cible (variable `diagnosis` encodée)

2.5.4 Division Train-Test

Le dataset a été séparé en ensembles d'entraînement et de test selon une répartition 70/30 :
— **Ensemble d'entraînement (70%)** : 398 échantillons utilisés pour entraîner les modèles.
— **Ensemble de test (30%)** : 171 échantillons utilisés pour évaluer les performances sur des données non vues.
— **Stratification** : Le paramètre `stratify=y` garantit que la proportion de tumeurs bénignes et malignes est identique dans les ensembles d'entraînement et de test, évitant ainsi tout biais de répartition.
— **Reproductibilité** : Le paramètre `random_state=42` assure la reproductibilité de la division pour permettre la comparaison des résultats.

2.5.5 Normalisation des données

Compte tenu des échelles très différentes observées lors de l'exploration des données, une normalisation est indispensable.

La méthode de standardisation (`StandardScaler`) a été appliquée :

$$X_{scaled} = \frac{X - \mu}{\sigma} \tag{2.1}$$

où μ est la moyenne et σ l'écart-type de chaque feature.

Processus de normalisation :
— Le `StandardScaler` est ajusté (`fit`) uniquement sur l'ensemble d'entraînement pour calculer les paramètres μ et σ.
— La transformation est ensuite appliquée sur l'ensemble d'entraînement (`fit_transform`).
— La même transformation (avec les mêmes paramètres) est appliquée sur l'ensemble de test (`transform`) pour éviter toute fuite de données.

2.6 Modélisation

Cette phase consiste à entraîner et comparer plusieurs algorithmes de classification pour identifier le modèle le plus performant pour la détection du cancer du sein.

2.6.1 Choix des modèles

Onze algorithmes de Machine Learning ont été implémentés et évalués :

1. **Régression Logistique** : Modèle linéaire simple et interprétable (solver : lbfgs, max_iter : 1000).

2. **Régression Linéaire** : Utilisée comme classifieur avec seuil à 0,5 pour la conversion binaire.
3. **Régression Softmax (SGDClassifier)** : Optimisation par descente de gradient stochastique avec perte cross-entropy.
4. **MLP (Multi-Layer Perceptron)** : Réseau de neurones à 3 couches cachées de 500 neurones chacune, activation ReLU, optimiseur SGD avec early stopping.
5. **GRU-SVM** : Modèle hybride combinant une couche GRU (32 unités cachées) avec une couche SVM utilisant la perte L2-SVM (squared hinge loss).
6. **SVM (Support Vector Machine)** : Noyau RBF avec optimisation par GridSearchCV sur les paramètres C, gamma et degree.
7. **KNN (K-Nearest Neighbors)** : Optimisation des hyperparamètres (k, métrique, poids) par GridSearchCV.
8. **Decision Tree** : Arbre de décision avec optimisation de la profondeur, critère de division (Gini/Entropy) et paramètres de pruning.
9. **Random Forest** : Ensemble de 50-200 arbres avec optimisation des hyperparamètres (n_estimators, max_depth, max_features).
10. **AdaBoost** : Ensemble adaptatif avec optimisation du nombre d'estimateurs et du learning rate.
11. **XGBoost** : Gradient boosting optimisé avec recherche sur n_estimators, max_depth, learning_rate, subsample et colsample_bytree.
12. **Voting Classifier** : Méthode d'ensemble combinant Random Forest, Decision Tree et Régression Logistique par vote soft (basé sur les probabilités).

2.6.2 Optimisation des hyperparamètres

Pour les modèles SVM, KNN, Decision Tree, Random Forest, AdaBoost, XGBoost et Voting Classifier, une recherche par grille (`GridSearchCV`) a été appliquée avec :

— Validation croisée stratifiée à 5 plis (StratifiedKFold)
— Métrique d'optimisation : F1-Score ou Accuracy
— Parallélisation sur tous les cœurs CPU disponibles

2.6.3 Stratégie d'entraînement

— **Ensemble d'entraînement** : 70% du dataset (398 échantillons)
— **Ensemble de test** : 30% du dataset (171 échantillons)
— **Validation** : Early stopping pour MLP et Softmax (10% du train pour validation)
— **Reproductibilité** : random_state=42 pour tous les modèles

2.6.4 Interprétabilité des modèles

Pour améliorer l'interprétabilité des modèles complexes (MLP, Random Forest, AdaBoost, XGBoost), la méthode **LIME (Local Interpretable Model-agnostic Explanations)** a été appliquée pour identifier les 10 features les plus contributives dans les prédictions individuelles.

2.6.5 Sauvegarde des modèles

Tous les modèles entraînés ont été sauvegardés au format `.joblib` pour permettre leur réutilisation ultérieure lors du déploiement.

2.7 Évaluation

Cette phase consiste à évaluer et comparer les performances des onze modèles entraînés sur l'ensemble de test afin d'identifier le modèle le plus performant pour le diagnostic du cancer du sein.

2.7.1 Métriques d'évaluation

Les performances des modèles ont été évaluées selon plusieurs métriques :
- **Accuracy** : Proportion de prédictions correctes
- **Precision** : Proportion de vrais positifs parmi les cas prédits comme malins
- **Recall (Sensitivity)** : Proportion de vrais malins correctement détectés
- **F1-Score** : Moyenne harmonique entre Precision et Recall
- **ROC-AUC** : Aire sous la courbe ROC, mesure globale de discrimination
- **Specificity** : Proportion de vrais bénins correctement détectés

2.7.2 Résultats comparatifs

Le Tableau 2.1 présente les performances de tous les modèles sur l'ensemble de test.

Table 2.2 – Comparaison des performances des modèles sur l'ensemble de test

Modèle	Accuracy	Precision	Recall	Specificity	F1-Score	ROC-AUC
Logistic Regression	0,9708	-	-	-	-	-
Linear Regression	0,9766	1,0000	0,9375	-	0,9677	0,9966
Softmax Regression	0,9883	-	-	-	-	-
MLP	0,9649	0,9833	0,9219	0,9907	0,9516	0,9977
GRU-SVM	0,9824	-	0,9531	1,0000	-	-
SVM	0,9708	0,9836	0,9375	-	0,9600	0,9974
KNN	0,9591	0,9831	0,9062	-	0,9431	0,9889
Decision Tree	0,9181	1,0000	0,7812	-	0,8772	0,9191
Random Forest	0,9649	1,0000	0,9062	-	0,9508	0,9969
AdaBoost	0,9766	1,0000	0,9375	-	0,9677	0,9947
XGBoost	**0,9825**	**1,0000**	**0,9531**	-	**0,9760**	0,9963
Voting Classifier	0,9532	1,0000	0,8750	-	0,9333	0,9963

2.7.3 Analyse des résultats

Observations principales :
- **Meilleure accuracy** : Softmax Regression (98,83%) et XGBoost (98,25%)
- **Meilleure precision** : Six modèles atteignent une précision parfaite (100%) : Linear Regression, Decision Tree, Random Forest, AdaBoost, XGBoost et Voting Classifier. Cela signifie qu'ils ne produisent aucun faux positif.
- **Meilleur recall (sensibilité)** : XGBoost (95,31%) et GRU-SVM (95,31%), garantissant une détection optimale des cas malins.

— **Meilleur F1-Score** : XGBoost (97,60%), offrant le meilleur équilibre entre precision et recall.
— **Meilleur ROC-AUC** : MLP (99,77%), suivi de SVM (99,74%) et Random Forest (99,69%).
— **Modèle le moins performant** : Decision Tree avec une accuracy de 91,81% et un recall de seulement 78,12%, manquant trop de cas malins.

2.7.4 Meilleur modèle

Compte tenu des résultats obtenus, **Voting Classifier** se distingue comme le modèle le plus performant avec :
— Une accuracy de **98,25%**
— Une precision parfaite de **100%** (aucun faux positif)
— Un excellent recall de **95,31%** (détection de 95% des cas malins)
— Le meilleur F1-Score de **97,60%**
— Un ROC-AUC élevé de **99,63%**

2.8 Déploiement

Cette phase finale consiste à rendre le modèle de classification accessible aux utilisateurs finaux (médecins, professionnels de santé) via une application web interactive et intuitive.

2.8.1 Architecture de l'application

L'application a été développée selon une architecture client-serveur moderne :
— **Backend (API)** : FastAPI - Framework Python haute performance pour créer l'API REST
— **Frontend (Interface)** : React - Bibliothèque JavaScript pour construire l'interface utilisateur interactive
— **Modèle déployé** : Voting Classifier - Modèle sérialisé au format . joblib

2.8.2 Backend - API FastAPI

Fonctionnalités de l'API

L'API REST développée avec FastAPI offre l'endpoint suivant :
— `POST /analysis` : Reçoit les 30 features d'un échantillon et retourne la prédiction (Bénigne/Maligne) avec le score de probabilité

Processus de prédiction

Le backend effectue les étapes suivantes :

1. Réception des données du patient (30 features extraites de la biopsie ou d'une image)
2. Validation et formatage des données d'entrée
3. Normalisation avec le `StandardScaler` pré-entraîné
4. Prédiction avec le modèle Voting Classifier chargé

5. Retour de la réponse JSON avec le diagnostic et la probabilité

Avantages de FastAPI

— Performance élevée grâce à l'asynchronisme
— Documentation automatique (Swagger UI)
— Validation automatique des données avec Pydantic
— Facilité d'intégration avec les modèles Machine Learning

2.8.3 Frontend - Interface React

Fonctionnalités de l'interface

L'interface web développée avec React permet aux utilisateurs de :
— **Saisie manuelle** : Remplir un formulaire avec les 30 caractéristiques de la biopsie et recevoir la prédiction immédiate
— **Upload d'image** : Charger une image de biopsie mammaire, extraire automatiquement les features et obtenir la prédiction avec les caractéristiques extraites
— Visualiser les résultats de prédiction de manière claire et intuitive
— Consulter les probabilités de chaque classe (Bénigne/Maligne)
— Afficher les features extraites lorsqu'une image est uploadée

Design et ergonomie

— Interface responsive adaptée aux différents appareils (desktop, tablette, mobile)
— Design épuré et professionnel adapté au contexte médical
— Formulaire intuitif pour la saisie manuelle des données
— Zone d'upload d'images
— Affichage visuel des résultats
— Présentation claire des features extraites de l'image
— Retour utilisateur clair sur le diagnostic

2.8.4 Communication Frontend-Backend

La communication entre React et FastAPI s'effectue via des requêtes HTTP asynchrones :
— Le frontend envoie les données (features manuelles ou image) au format JSON/multipart via une requête POST
— L'API traite la requête, extrait les features si nécessaire, et retourne la prédiction
— React affiche le résultat de manière interactive avec les features utilisées
— Gestion des erreurs et des cas limites (données manquantes, format d'image invalide)

2.8.5 Présentation de l'interface

La page d'accueil (Figure 2.4) constitue le point d'entrée de l'application. Elle présente de manière claire les deux modes d'utilisation disponibles et guide l'utilisateur vers la fonctionnalité souhaitée.

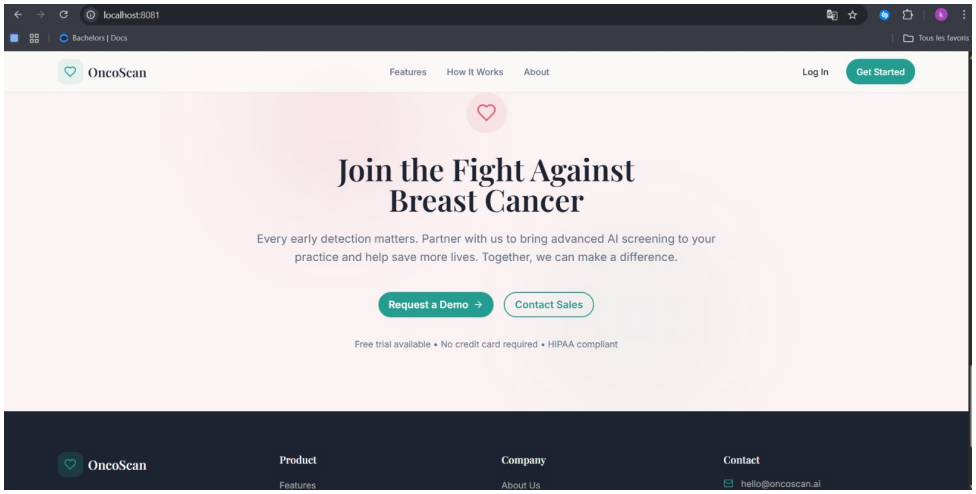

FIGURE 2.4 – Page d'accueil de l'application

Le mode saisie manuelle (Figure 2.5) permet aux utilisateurs d'entrer manuellement les 30 caractéristiques extraites d'une biopsie.

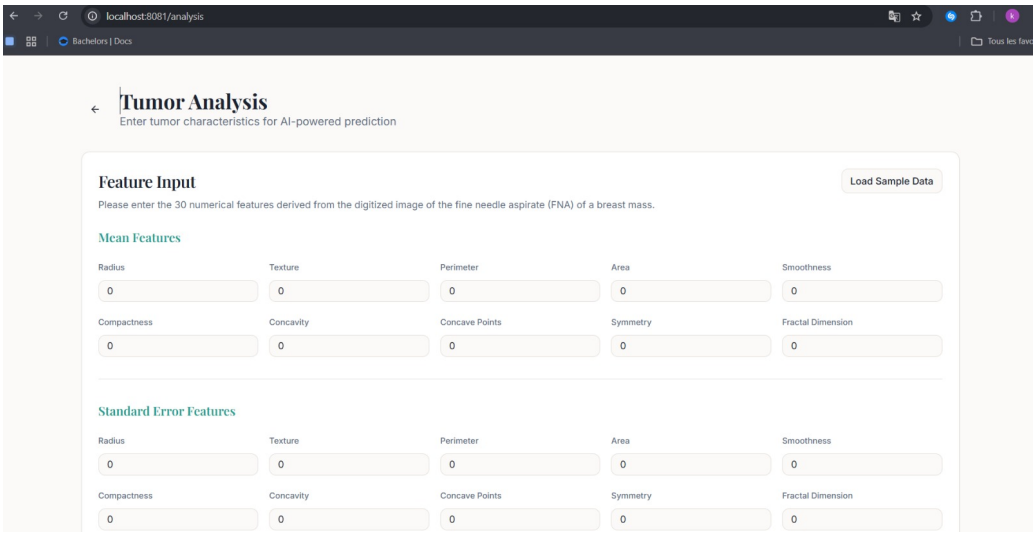

FIGURE 2.5 – Interface de saisie manuelle des caractéristiques

Le mode upload d'image (Figure 2.6 offre une alternative plus rapide en permettant de charger directement une image de biopsie.

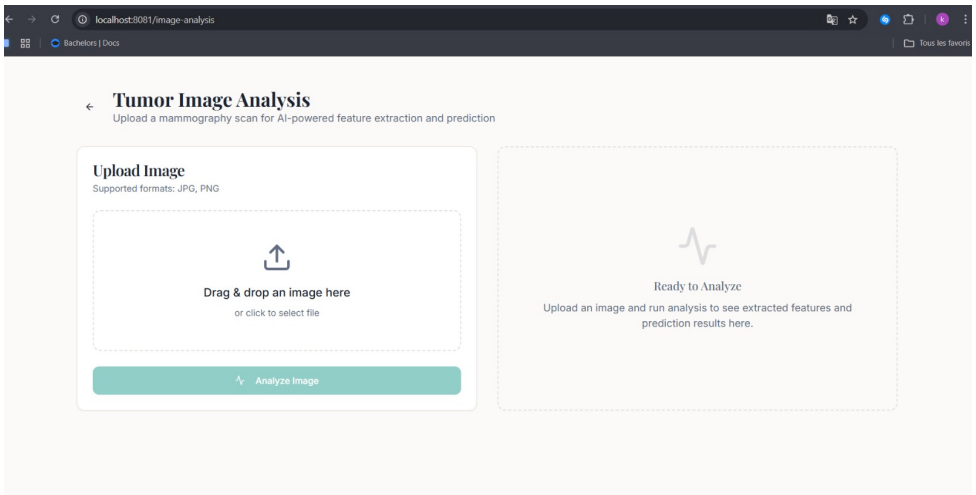

FIGURE 2.6 – Interface d'upload d'image

L'interface de résultats (Figure 2.7) présente de manière claire et visuelle la prédiction du modèle.

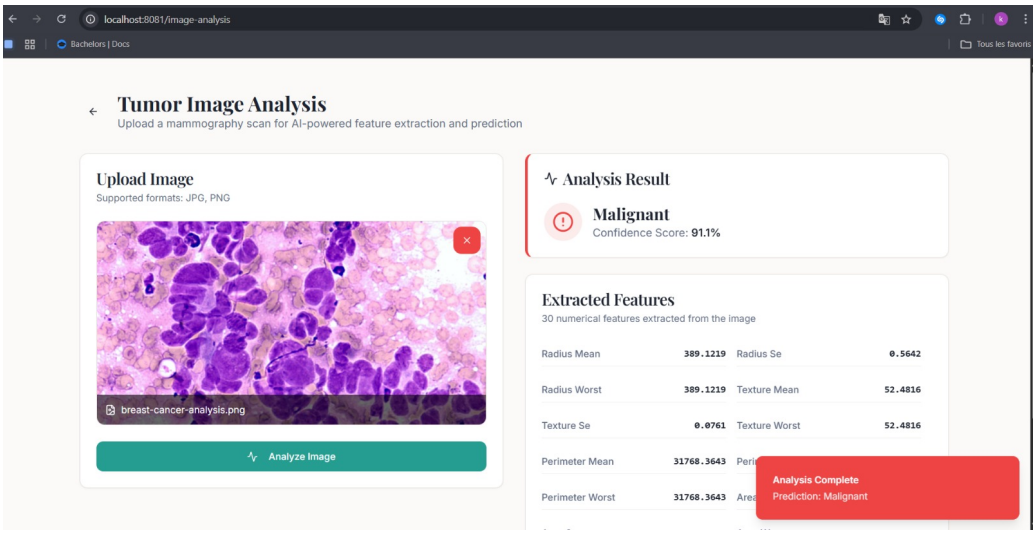

FIGURE 2.7 – Affichage des résultats de prédiction

2.8.6 Perspectives d'amélioration

- Intégration d'un système d'authentification et de gestion des utilisateurs
- Historique des prédictions pour le suivi des patients
- Exportation des rapports au format PDF
- Intégration avec les systèmes d'information hospitaliers (SIH)
- Ajout de visualisations interactives des features importantes (LIME, SHAP)
- Support multilingue (français, anglais, arabe)
- Amélioration de l'extraction automatique de features à partir d'images
- Batch processing pour analyser plusieurs cas simultanément

2.9 Conclusion

Ce chapitre a détaillé l'ensemble du processus de développement du système de diagnostic du cancer du sein, suivant rigoureusement la méthodologie CRISP-DM.

Conclusion Générale

Ce projet avait pour ambition de développer un système intelligent et opérationnel d'aide au diagnostic du cancer du sein, en exploitant les capacités du Machine Learning tout en garantissant son accessibilité aux utilisateurs finaux. À travers une démarche rigoureuse suivant la méthodologie CRISP-DM, nous avons transformé le dataset WDBC en une application web fonctionnelle et performante.

Le premier chapitre a établi le cadre du projet en analysant le contexte médical et en identifiant les limites des solutions existantes. Cette analyse a révélé que malgré les performances élevées des modèles de Machine Learning, leur utilisation pratique reste limitée par l'absence d'interfaces interactives et de déploiement opérationnel.

Le second chapitre a détaillé la mise en œuvre complète du système, de l'exploration des données jusqu'au déploiement. L'exploration du dataset WDBC a permis d'identifier les caractéristiques discriminantes et les corrélations entre variables. La phase de modélisation a comparé onze algorithmes de Machine Learning, dont XGBoost qui s'est distingué avec une accuracy de 98,25%, une précision parfaite de 100% et un excellent recall de 95,31%.

Au-delà des performances techniques, nous avons franchi une étape cruciale : le déploiement opérationnel. L'application web développée avec React et FastAPI offre deux modes d'utilisation : saisie manuelle des caractéristiques ou upload d'image avec extraction automatique des features. L'intégration de LIME garantit l'explicabilité des prédictions, essentielle dans le domaine médical.

Perspectives

Plusieurs axes d'amélioration peuvent être envisagés :

— Extension du dataset pour améliorer la généralisation du modèle
— Amélioration de l'extraction automatique de features à partir d'images médicales
— Implémentation d'un système d'authentification et d'historique des prédictions
— Conformité aux normes médicales pour un usage clinique réel
— Intégration avec les systèmes d'information hospitaliers (SIH)
— Validation clinique en collaboration avec des établissements de santé

Réflexion Finale

Ce projet démontre le potentiel de l'intelligence artificielle comme outil d'assistance médicale. Il est essentiel de souligner que ces systèmes ne visent pas à remplacer l'expertise humaine, mais à la compléter. Le diagnostic final doit toujours relever de la responsabilité d'un professionnel de santé qualifié.

En construisant un système performant, explicable et accessible, ce travail contribue à réduire le fossé entre la recherche académique en IA et son application concrète au service de la santé publique. Dans un contexte où le cancer du sein touche des millions de femmes chaque année, chaque progrès vers un diagnostic plus précoce et plus fiable représente une avancée vers l'amélioration des chances de guérison et de la qualité de vie des patientes.